

Aprendizaje Automático y Minería de Datos - Proyecto final

David Ignacio Alcántara García y Marta López Rauhut

Mayo 2022

1. Introducción

El propósito de este proyecto es la aplicación de diversos algoritmos de minería de datos y aprendizaje automático sobre un conjunto de datos escogido. En concreto, se estudiarán los resultados de una encuesta realizada a españoles graduados en el curso 2013/2014, recopilados en el año 2019 por el Instituto Nacional de Estadística.

Se pretende investigar si existe alguna relación entre su perfil sociodemográfico, titulaciones obtenidas, competencias lingüísticas o digitales, diferentes actividades formativas y su situación laboral y personal actual, incluyendo dificultades para encontrar empleo, sueldo medio, movilidad o situación doméstica.

De esta forma, a partir de los datos se intentarán predecir las situaciones con las que se podrían topar en un futuro quienes están estudiando actualmente en España.

Todas las figuras y archivos generados durante la realización del proyecto se pueden localizar en la correspondiente [carpeta de OneDrive](#).

2. Estadística descriptiva

El dataset puede encontrarse en [Kaggle.com](#), y recopila 298 atributos, la gran mayoría de ellos categóricos, acerca de 31651 graduados españoles encuestados. Los atributos se clasifican en 7 bloques:

A Datos personales y sociodemográficos

B Educación y aprendizaje del graduado universitario

Este es el bloque más amplio. Contiene información acerca de:

- a)* Becas
- b)* Estudios universitarios
- c)* Ciclos formativos
- d)* Idiomas
- e)* Cursos

C Movilidad

D Situación actual del graduado universitario

E Historial laboral del graduado universitario

F Información del hogar

G Variables adicionales

En bastantes se da una proporción elevada de valores NA (nulos), principalmente porque existen dependencias entre atributos. Por ejemplo, si un encuestado contesta “no” a si obtuvo alguna beca, todos los atributos relacionados




Figura 1: Proporción de valores nulos por atributo

Row ID	S Column	D ▲ Min	D Max	D Mean	D Variance	Histogram
#8 @...	#8 @A Rama de conocimiento de la titulación [RAMA] {TRAMA}	1	5	3.207	1.225	
#10 ...	#10 @A Tipo de Universidad [T_UNIV] {TTPUNIV}	1	4	1.357	0.636	
#11 ...	#11 @A Tiene discapacidad reconocida superior al 33% [DISCA] {T1SINO}	1	2	1.988	0.012	

Figura 2: Frecuencia de las distintas clases en algunos atributos

con los tipos de becas recibidas serán no aplicables. En la figura 1 se muestra la cantidad de valores nulos para cada atributo.

Además, en ciertos atributos sin valores de este tipo, las clases presentan un sesgo elevado en sus valores. En la figura 2 se pueden ver algunos de los atributos con esta característica, junto con otros mejor distribuidos.

A continuación, se muestran también, en las figuras 3 y 4, una visualización de las primeras 2 componentes de PCA, así como una proyección bidimensional generada por el método t-SNE, utilizando la rama de estudio para etiquetar los colores.

Por último, resulta interesante observar la matriz de covarianzas de todos los atributos del conjunto de datos, que aparece en la figura 5, en la que se han delimitado los distintos bloques de atributos. Esto permite observar también que la correlación entre atributos de distintos bloques es, en general, bastante débil, lo que hará difícil la tarea de clasificación.

3. Preprocesado

Algunas de las aplicaciones de minería de datos que se han utilizado requieren datos en formato numérico normalizado, mientras que otras necesitan clases únicas.

Además, la mayoría de atributos están codificados, lo que crea complicaciones tanto para entender los valores como para aplicar técnicas numéricas cuando los datos están arbitrariamente separados por la asignación de los códigos en subcategorías, como las que usa el atributo 7, del Ámbito de estudio, que representa los datos usando 4 dígitos de forma jerárquica, a veces omitiendo el último si es 0.

Esta forma de asignar códigos crea una distribución espacial artificialmente sesgada en los datos, y por ello ha sido necesario adaptar la transformación numérica en consecuencia. También existen atributos con códigos no numéricos, en particular el atributo CNAE de clasificación de actividades económicas. En este caso, se asigna a cada código alfanumérico un índice único.

Por otra parte, la gran cantidad de atributos y sus nombres codificados hacen muy difícil trabajar con ellos o generar gráficas y reglas de asociación.




Figura 3: Primeras 2 dimensiones de PCA



Figura 4: t-SNE del conjunto de datos en 2 dimensiones

Por estos motivos, se ha realizado una primera fase de preprocesado de los datos, en la que se extrae toda la información disponible de la leyenda y se condensa en los encabezados de los atributos. Los encabezados generados utilizan el formato `#id @BLOQUE Descripción [CÓDIGO] {TIPO}`, de forma que es posible acceder a todos estos atributos según sea necesario. En particular, este formato permite filtrar por bloques de atributos o tipos con facilidad.

Adicionalmente, se ha creado una segunda tabla a partir de la leyenda, que contiene la traducción de los códigos para cada tipo de datos, así como un componente que permite reemplazar los códigos utilizando este diccionario de códigos. Esta tabla también se ha utilizado para normalizar todos los códigos asociados a valores de NA y NS/NC como valores nulos, ya que el código que denota este valor es distinto para cada tipo de datos, y a menudo es un valor extremo numérico. Para algunas aplicaciones que requieren datos numéricos, los valores nulos se han normalizado como -1 , pues la gran proporción de elementos nulos, hacen difícil poder ignorarlos sin perder una gran porción de la información.

4. Modelos utilizados

Los únicos atributos numéricos que se podrían emplear para hacer regresión no se consideran especialmente relevantes. Por otro lado, para aplicar los conocimientos aprendidos se podría hacer una pseudo-regresión sobre el sueldo o el número de años hasta encontrar un empleo, sustituyendo cada categoría por su valor medio numérico o similar.

Por este motivo, las principales tareas que se desean realizar son clasificación, clustering y búsqueda de reglas de asociación. En concreto, se pretende experimentar utilizando los siguientes algoritmos:

- Clustering
 - k-Means
 - Expectation-Maximization
- Reglas de asociación
- Clasificación
 - Regresión logística
 - SVM
 - Redes neuronales




Figura 5: Matriz de covarianzas

- RProp MLP Learner
- Red neuronal de Keras
- k-Nearest Neighbours
- Random forest

Se verá más adelante que no todos son aplicables debido a las dimensiones del dataset, aunque sí por su formato.

5. Desarrollo

5.1. Clustering

Se comienza aplicando un modelo no supervisado para obtener una visión general de los datos y las principales agrupaciones, para luego encaminar el análisis posterior con modelos supervisados. Para este ejercicio se utilizan todos los datos sin particionar en train y test, puesto que el objetivo es la visualización y no la predicción.

Las primeras dificultades que surgen al aplicar segmentación al dataset son el elevado número de atributos, que complica la interpretación de los resultados así como la obtención de clusters representativos, y la selección de un k apropiado.

Para remediar el primer problema, surge la idea de aplicar PCA. Sin embargo, si se hace esto no hay forma de saber qué atributos reales influyen en el clustering. Por lo tanto, se filtran manualmente ciertos conjuntos de atributos para obtener clusters más significativos en regiones interesantes, como extra aparte de la segmentación del dataset completo.

En cuanto al segundo problema: el nodo EM de Weka permite seleccionar k de forma dinámica, pero los que implementan k-Means no. Por este motivo, para k-Means se aplica el método del codo mediante un bucle que obtiene, para un rango de valores de k , la suma de las distancias euclídeas al cuadrado de cada punto al centroide de su cluster. Los resultados se trazan en una gráfica para seleccionar el k más adecuado de forma visual. La implementación se inspira en la encontrada en Knime Hub.

Un problema detectado es que el algoritmo en ocasiones no avanza más allá de un óptimo local, haciendo que la gráfica presente picos en vez de ser decreciente. Cuando esto ocurre, se aumenta el número de iteraciones y/o se utiliza otra semilla aleatoria hasta que el resultado es razonable.

Una vez realizado el clustering, se interpretan los resultados gráficamente representando los valores correspondientes a los centroides en mapas de calor que permiten apreciar en qué atributos hay más contraste entre clusters.

5.1.1. k-Means

Análisis global

Se escoge $k = 7$, aunque no hay un codo claro en la gráfica resultante tras aplicar el método del codo.

El mapa de calor que representa los centroides es bastante amplio debido al elevado número de atributos, pero por suerte no se pretende realizar un análisis exhaustivo sino identificar las principales diferencias entre clusters. Estas aparecen en el grupo de edad, si realizaron otros estudios (otra Licenciatura/Diplomatura/Grado o máster), si están desempleados, si tuvieron algún trabajo remunerado durante la realización de sus estudios y en datos relativos a su afiliación y cotización en la Seguridad Social entre 2015 y 2019.

Se distinguen los desempleados no afiliados a la Seguridad Social de los sí afiliados. Entre ambos clusters hay diferencias también en si tuvieron un trabajo remunerado al finalizar (o durante) los estudios y la búsqueda de empleo.

De todas formas, estos resultados varían de ejecución en ejecución según la semilla aleatoria escogida y por tanto son solo orientativos de qué atributos permiten separar la muestra en grupos, y cuáles no parecen ser tan relevantes.

Filtrado

Ahora, se filtra el dataset para ver los clusters resultantes teniendo en cuenta solo los títulos y la situación laboral actual de los encuestados, añadiendo información acerca de las becas obtenidas. Aplicando nuevamente el método del codo, se escoge $k = 6$.

En la figura 6 se muestran los valores normalizados de los atributos categóricos iniciales. Para interpretar su significado hay que tener en cuenta la leyenda original del dataset y su traducción: los valores más cercanos a 0 representan que el atributo no es aplicable. En cuestiones de sí o no, un valor bajo representa “sí” uno alto, “no”, y no hay NA. En preguntas que se contestan con un número aproximado, por ejemplo el número de otros estudios cursados, valores menores representan rangos más bajos y viceversa, y hay NA para quienes no han cursado otros estudios. El valor cercano a 1 en “Tipo de jornada de trabajo actual” se debe a una gran proporción de valores “NS/NC”.




Figura 6: Clustering sobre atributos de los bloques B y D

Los datos se han segregado principalmente según el número de otros estudios (Grado, Diplomatura, Licenciatura o

equivalente), si el graduado cursó un máster y en parte si realizó ciclos formativos de grado superior en formación profesional, artes plásticas y diseño o Enseñanzas Deportivas de Grado Superior. Se han separado además los empleados de los desempleados (atributos de situación laboral en blanco, correspondientes al valor NA) y quienes han completado sus estudios de los que no, con diferencias en el número de otros estudios.

No se aprecian diferencias significativas entre clusters para las becas concedidas o la situación laboral actual concreta, fuera de si el graduado está actualmente empleado o no. Tras repetir el experimento con diferentes semillas aleatorias, los resultados son similares. Es decir, no parece que la concesión de becas tenga un fuerte impacto en la situación laboral. Por otro lado, hay una diferencia sutil en los atributos de becas de quienes cursaron más de un Grado: parece ser que en general un mayor número de ellos fueron concedidos alguna beca.

Como resumen, se indican las tendencias principales que se aprecian en cada cluster, junto con su tamaño relativo:

- **Cluster 5** (29.92 %): graduados con Máster, pero sin más titulaciones.
- **Cluster 2** (25.762 %): graduados sin más estudios, empleados.
- **Cluster 0** (19.137 %): principalmente graduados con más de un Grado, algunos con Máster, y sin más estudios.
- **Cluster 4** (10.878 %): con ciclos formativos de grado superior.
- **Cluster 1** (9.712 %): desempleados/inactivos con más estudios de diferente tipo.
- **Cluster 3** (4.591 %): graduados sin más estudios, desempleados/inactivos.

Esto no quiere decir que cada cluster recoja exclusivamente estos grupos, sino que son los atributos que más destacan en cada uno de ellos.

5.1.2. Expectation-Maximization

No se puede aplicar EM a este dataset debido a su elevada complejidad temporal: el nodo EM de Weka solo termina la ejecución en un tiempo razonable cuando se emplea el 5% de los datos o menos. En concreto, un 5% de los datos filtrando solo el bloque E (62 atributos). Este es un valor poco representativo de la muestra y por lo tanto no merece la pena realizar el análisis con este algoritmo.

Aun así, se experimentó con la posibilidad que ofrece el nodo para seleccionar k de forma dinámica por *cross-validation*, comparándola con la implementación del método del codo seleccionando un k estático en cada iteración. Se pudo adaptar directamente la versión para k-Means sin más que añadir un paso para calcular los centroides y realizar algún que otro ajuste.

5.2. Reglas de asociación

Para encontrar reglas de asociación, se prueban dos nodos: tanto Association Rule Learner de Knime como Predictive Apriori de Weka. Tras comparar el formato de la salida de ambos, finalmente se escoge Association Rule Learner para poder manipular los resultados y filtrar reglas interesantes según un criterio personal. Otro motivo de importancia es el hecho de que Predictive Apriori no puede manejar los tipos de todas las columnas del dataset, a pesar del preprocesado.

En la salida del nodo solo se muestran los valores de los atributos, así que para poder interpretar las reglas resultantes, es necesario introducir un prefijo con el atributo con el que se corresponde el valor de cada celda, ya que de los 298 atributos muchos utilizan las mismas categorías. Esto se añade a la funcionalidad del componente de traducción.

Se escoge un umbral de soporte $\tau = 0,5$ y de confianza $\gamma = 0,9$. Idealmente el umbral de soporte sería el mínimo posible, para obtener reglas que se apliquen también a subconjuntos minoritarios, como por ejemplo los desempleados, pero por debajo de 0,5 el tiempo de ejecución deja de ser asumible.

Además, para evitar que en las reglas aparezcan siempre los atributos que predominan en el dataset, se filtran antes de aplicar el algoritmo aquellos con una varianza inferior a 0.05. Finalmente, para una mejor visualización de los resultados, se añade un componente que permite filtrar las reglas resultantes por el bloque del consecuente y las premisas.

A pesar de las medidas aplicadas, la mayoría de las reglas resultantes involucran valores predominantes y, en consecuencia, no aportan demasiada información. Por ejemplo, “País de residencia: España $\implies$ Trabajando”, cuando se pretendía encontrar relaciones entre la situación laboral actual y la rama de estudios o la educación adicional del graduado. Si se dispusiera de una mayor potencia de cómputo se podría haber reducido el umbral de soporte lo suficiente como para obtener alguna regla relacionada con estos atributos.

A continuación se muestran como ejemplo algunas de las reglas obtenidas tras filtrar el dataset. Sin filtrar, las más comunes son similares a las que se muestran aquí. No se obtuvieron reglas con consecuentes en los bloques B, C ni F.

Filtrando para consecuente en D y premisas en A, B y E no se encontraron premisas en B, solo en A y E:

Premisas	Consecuente	τ	γ
E. Ha estado trabajando 2 o más años	Trabajando	0,779	0,918
E. Ha estado trabajando 2 o más años E. No buscó empleo por otros medios E. No buscó empleo por empresas de trabajo temporal	Trabajando	0,722	0,922

Con consecuentes en A y E y premisas en D, es decir, invirtiendo los bloques del consecuente y las premisas:

Premisas	Consecuente	τ	γ
Trabajando	E. Ha estado trabajando 2 o más años	0,779	0,909
Trabajando Trabajando en España	A. Vive en España	0,777	0,966

5.3. Clasificación

Dada la gran cantidad de atributos del conjunto de datos, existe un elevado número de posibles tareas de clasificación. Sin embargo, por su naturaleza, para el fin de clasificación solo nos pueden importar realmente las situaciones en las que predecimos un atributo de los bloques D o E en función de la información de los bloques que se pueden conocer a priori, i.e., A y B.

En concreto, se han clasificado 3 atributos elegidos por su interés:

- Sueldo mensual neto actual
- Tiempo transcurrido desde que finalizó estos estudios hasta que empezó a trabajar
- Situación profesional de su primer empleo

La clasificación se ha abstraído utilizando un metanodo que prueba cada uno de los 5 métodos que se han utilizado y compara sus resultados, para cada atributo.

En este nodo, hay una sección inicial de preprocesado que es compartida por los diferentes métodos, así como una sección final que recoge las métricas de cada método.

5.3.1. Dificultades

Durante el proceso de desarrollo de los distintos métodos de clasificación, se han encontrado algunas dificultades, la mayoría como consecuencia del gran número de atributos y filas manejado.

Por ejemplo, el algoritmo de **regresión logística** no es capaz de converger si no se reduce previamente la dimensionalidad por medio de PCA, como se ha hecho preservando un 95 % de la varianza inicial, que corresponde a 89 componentes de las 118 pertenecientes a los bloques A y B.

Por otra parte, el número de instancias m es muy grande en relación al número de atributos p (31651 respecto a 298), así que no es factible aplicar **SVM** sobre este dataset. Aunque se seleccione únicamente un 1 % de los datos, el entrenamiento es costoso hasta con el kernel polinómico (el más sencillo disponible en el nodo SVM Learner de Knime), aparte de que se obtendrían muy malos resultados en la predicción al no ser una porción representativa.




Figura 7: Representación de la red de Keras utilizada

Asimismo, la gran cantidad de clases de salida de los atributos elegidos, en ocasiones puede resultar en que los clasificadores decidan ignorar las clases menos frecuentes, incluso a pesar de tomar la división de los datos estratificada sobre el atributo clasificado.

Para hacer frente a este problema, se realizaron pruebas aplicando la técnica SMOTE, que genera datos sintéticos de entrenamiento para compensar la escasa frecuencia de las clases minoritarias utilizando interpolación lineal de k vecinos. Sin embargo, si bien esta técnica permitió mejorar la precisión total de los clasificadores realizando la validación sobre los datos aumentados, utilizando solo los datos originales para la validación la precisión disminuía, incluso tomando $k = 1$, es decir, únicamente duplicando datos de las clases minoritarias. Por este motivo, la técnica SMOTE no ha sido utilizada en los modelos finales.

Otro problema es que en el caso del predictor **MLP** de Knime, no es posible obtener de forma eficiente una curva de aprendizaje para evaluar el entrenamiento. Por ello, se ha utilizado también un clasificador de **Keras**, gracias a la integración de Knime con Keras. Este clasificador permite determinar a partir de qué punto la red empieza a sobreajustarse.

La red de Keras utilizada consta de 3 capas internas densas con número decreciente de neuronas: 256, 64 y 16, como muestra la figura 7, utilizando capas de dropout interpuestas del 20 %, 20 % y 10 % respectivamente, para mitigar o ralentizar el sobreajuste que se pueda producir en el entrenamiento.

Para utilizar el clasificador de Keras ha sido necesario adaptar la columna de clases en múltiples columnas de clasificación binaria, así como deshacer este cambio tras la predicción para poder comparar las métricas de precisión con el resto de clasificadores.

5.3.2. Optimización de parámetros

Las estrategias de optimización de parámetros son diferentes en cada clasificador.

En el caso de la **regresión logística**, la principal preocupación es conseguir que el modelo converja, lo que se pudo conseguir hacer gracias a la reducción de dimensionalidad.

En el caso del clasificador por **k-Nearest Neighbours**, se ha buscado el mejor número de vecinos utilizando la partición de validación cruzada. Como se observa en la figura 8, la precisión aumenta con el número de vecinos hasta converger en un cierto valor. Por ello, se ha utilizado una estrategia de escalada para encontrar el valor óptimo de vecinos.

En el caso del predictor **MLP**, dada la gran cantidad de atributos, y debido al tiempo de entrenamiento del




Figura 8: Evolución de la precisión de k-NN al aumentar el número de vecinos




Figura 9: Curva de aprendizaje del clasificador de Keras

predictor, se ha decidido establecer una cantidad fija de neuronas, 100, y decidir la mejor forma de distribuir las en distintas capas para cada atributo utilizando la partición de validación cruzada.

Por otra parte, en la red neuronal de **Keras**, se ha utilizado la curva de aprendizaje para determinar el número de iteraciones que maximiza la precisión de validación cruzada, ya que con un número elevado de iteraciones, el modelo se sobreajusta, como puede observarse en la figura 9.

Finalmente, en el caso de **Random Forest**, los únicos parámetros a mejorar son el número de árboles y la profundidad máxima de cada árbol, pero la precisión siempre aumenta en general al aumentar el número de árboles, si bien de forma exponencialmente decreciente. Por tanto, se ha elegido un tamaño fijo de árboles con el fin de acotar el tiempo de computación.

5.3.3. Resultados

Los resultados obtenidos con cada clasificador aparecen recogidos en la figura 11, en la que puede apreciarse que las precisiones relativas de los distintos métodos de clasificación son esencialmente iguales para cada atributo.



Figura 10: Mejor precisión relativa en cada atributo




Figura 11: Precisión por modelos

El modelo con mayor precisión en los tres casos es Random Forest, con precisiones del 42,1 %, 37,9 % y 52,6 %. Para poder medir justamente la precisión de estos clasificadores, es necesario compararlos con el clasificador trivial,

como se muestra en la figura 10, que recoge una comparación de las precisiones relativas del mejor modelo para cada atributo.

Como se puede observar, en cada uno de los tres atributos se ha obtenido un clasificador entre 2 y 3 veces mejor que el trivial.

6. Conclusiones

En este proyecto se han podido apreciar las limitaciones que impone la complejidad temporal de los algoritmos de aprendizaje y minería de datos, puesto que el tiempo de ejecución de algunos de ellos ha supuesto un claro obstáculo para un conjunto de datos de tamaño medio. En relación con esto, se ha visto la utilidad de métodos de reducción de la dimensionalidad como PCA y t-SNE, tanto para la visualización de los datos como para reducir de la complejidad del análisis, consiguiendo en ocasiones que un algoritmo previamente no aplicable pase a serlo.

También se ha observado la importancia de la selección adecuada de los parámetros en modelos de aprendizaje, en particular en los algoritmos de clasificación, así como la utilidad de diferentes técnicas de validación cruzada.

En cuanto al problema tratado, desafortunadamente no se ha conseguido entrenar predictores que podamos llamar fiables -aunque sí mejores que el trivial- ni extraer resultados que esclarezcan lo incierto de nuestro futuro, pero en el proceso se ha adquirido algo más conocimiento acerca de un panorama no actual, pero sí reciente.

En cierto modo, puede considerarse incluso reconfortante que nuestro futuro sea tan difícil de predecir, y no dependa únicamente de los escasos parámetros que recoge la encuesta que hemos estudiado.

Referencias

Knime Hub. Elbow Method - hayasaka. <https://hub.knime.com/hayasaka/spaces/Public/latest/ScienceCafe-2021-01-25/ElbowMethod~Bk0qD38ZfLPn7YXQ>, 2022. [Consultado el 22 de mayo de 2022].